VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
INFORMACINIŲ SISTEMŲ INŽINERIJOS STUDIJŲ PROGRAMA

Pirma užduotis (Dirbtinis neuronas)

Laboratorinio darbo ataskaita

Atliko: Klaidas Kubilius

VU el. p.: klaidas.kubilius@mif.stud.vu.lt

Vilnius
2025

1. DARBO EIGA

1.1. Užduoties tikslas

Tikslas - Išanalizuoti dirbtinio neurono modelio veikimo principus.

1.2. Sugeneruoti duomenys

1.1 lentelė. Sugeneruotų duomenų koordinatės

X	Y	Class
1.62	2.14	0
3.96	3.42	0
2.05	4.78	0
3.13	4.41	0
1.06	1.01	0
4.67	3.08	0
4.60	3.21	0
1.13	2.94	0
4.83	4.07	0
1.55	1.64	0
9.06	8.81	1
6.08	7.31	1
6.54	7.34	1
6.47	9.91	1
7.24	8.50	1
8.69	9.80	1
7.88	9.07	1
9.26	9.30	1
7.16	7.63	1
8.93	7.81	1

Duomenys išskaidyti į dvi klases: pirma klasė (0) turi x ir y koordinates nuo 1 iki 5, o antroji klasė (1) – nuo 6 iki 10.

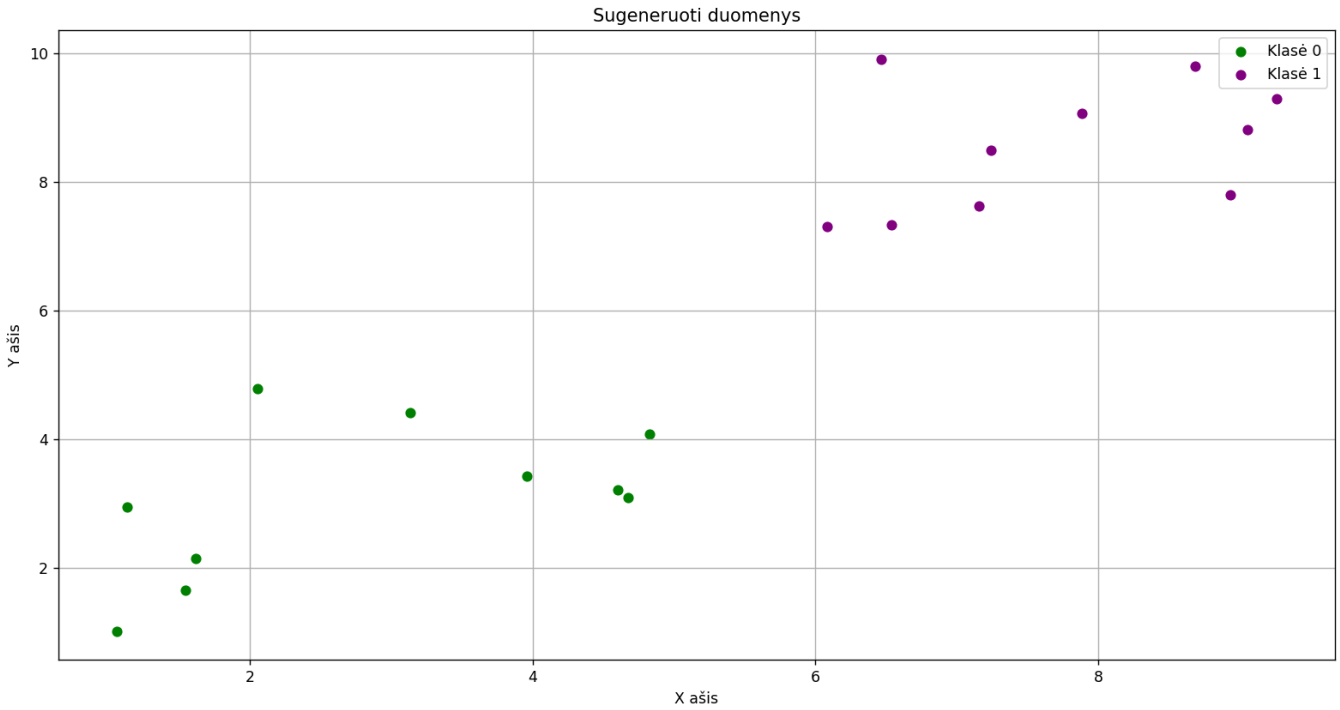

1.1 pav. Sugeneruoti duomenys koordinačių sistemoje

1.3. Programos kodas

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import sys
sys.stdout.reconfigure(encoding='utf-8')

# sėklos reikšmė atkuriamumui
np.random.seed(12)

# Generuojama pirma klasė (žalia) (nuo 1 iki 5)
class1_x = np.random.uniform(1, 5, 10)
class1_y = np.random.uniform(1, 5, 10)
class1 = np.column_stack((class1_x, class1_y))

# Generuojama antra klasė (violetinė) (nuo 6 iki 10)
class2_x = np.random.uniform(6, 10, 10)
class2_y = np.random.uniform(6, 10, 10)
class2 = np.column_stack((class2_x, class2_y))

# Sujungiami duomenys
labels = np.array([0] * 10 + [1] * 10)  # 0 - pirma klasė, 1 - antra klasė
X = np.vstack((class1, class2))

# Vizualizuojame duomenis
plt.figure(figsize=(6, 6))
plt.scatter(class1[:, 0], class1[:, 1], color='green', label='Klasė 0')
plt.scatter(class2[:, 0], class2[:, 1], color='purple', label='Klasė 1')
plt.xlabel("X ašis")
plt.ylabel("Y ašis")
plt.title("Sugeneruoti duomenys")
plt.legend()
plt.grid(True)
plt.show()

# Išspausdinti taškų koordinates ir klases
for (x, y), label in zip(X, labels):
```

```
    print(f"Koordinatės: ({x:.2f}, {y:.2f}), Klasė: {label}")

# Aktyvacijos funkcija
activation = 'sigmoid' # 'threshold' (slenkstinė) arba 'sigmoid' (sigmoidinė)
weights_bias_sets = []

for i in range(3):  # Trys tinkami rinkiniai
    for i in range(10000):  # Bandymų skaičius
        w = np.random.uniform(-1, 1, 2)
        b = np.random.uniform(-1, 1)
        a = np.dot(X, w) + b

        if activation == 'threshold':
            output = np.where(a >= 0, 1, 0)
        elif activation == 'sigmoid':
            output = np.round(1 / (1 + np.exp(-a)))
        else:
            raise ValueError("Nežinoma aktyvacijos funkcija")

        if np.array_equal(output, labels):
            weights_bias_sets.append((w, b))
            print(f"Rasti {activation} tinkami svoriai {len(weights_bias_sets)}: {w},
Bias: {b}")
            break



# Vizualizuojame duomenis, tieses ir svorių vektorius
plt.figure(figsize=(5, 5))
plt.scatter(class1[:, 0], class1[:, 1], color='green', label='Klasė 0')
plt.scatter(class2[:, 0], class2[:, 1], color='purple', label='Klasė 1')

colors = ['red', 'blue', 'orange'] # Tiesių ir vektorių spalvos
for i, (w, b) in enumerate(weights_bias_sets):
    if w is not None:   # Tikriname ar svoriai rasti
        x_vals = np.linspace(0, 10, 100)
        y_vals = -(w[0] * x_vals + b) / w[1]
        plt.plot(x_vals, y_vals, color=colors[i], linestyle='dashed', label=f'Tiesė
{i+1}')

        # Pasirenkame tašką ant tiesės (x=5)
        x0 = 5
        y0 = -(w[0] * x0 + b) / w[1]

        # Vektoriai atvaizduojami kaip rodyklės
        plt.quiver(x0, y0, w[0], w[1], color=colors[i], angles='xy', scale_units='xy',
scale=0.08, width=0.005)

plt.xlabel("X ašis")
plt.ylabel("Y ašis")
plt.title("Duomenys su klasifikavimo tiesėmis ir vektoriais")
plt.legend()
plt.grid(True)
plt.axis('equal')  # Vektoriai statmeni

# Nustatome x ir y ašių ribas nuo 0 iki 10
plt.xlim(0, 10)
plt.ylim(0, 10)

plt.show()
```

1.4. Svorių ir poslinkių paieška

Svoriai ir poslinkiai buvo ieškomi atsitiktinai generuojant skaičius tarp -1 ir 1 iki 10000 bandymų, po 3 rinkinius: 2 svorius ir poslinkį. Aktyvacijai naudojama slenkstinė arba sigmoidinė

funkcija. Kai naudojama slenkstinė funkcija, jei gauta reikšmė a≥0a, tai priklauso klasei 1, o jei a<0, tada klasei 0. Kai naudojama sigmoidinė funkcija, apskaičiuojama pagal formulę $\frac{1}{1+e^{-a}}$ ir rezultatas apvalinamas iki 0 arba 1. Tada gauta reikšmė palyginama su tikrąja taško klase.

1.5. Svorių ir poslinkio reikšmių rinkiniai

Svoriai ir poslinkio rinkiniai slenkstinei ir sigmoidinei funkcijai gaunasi tokie patys.

1.2 lentelė. Svorių ir poslinkio rinkiniai

Rinkiniai	Svoris W1	Svoris W2	Poslinkis b
1	0.15342852	-0.00286854	-0.7511472642633321
2	0.04687523	0.13270317	-0.9936566860936882
3	0.05669221	0.08075526	-0.8292815333363901

1.6. Duomenų taškų, tiesių ir vektorių grafikas

Grafike pavaizduoti klasių duomenų taškai, jas skiriančios tiesės ir jų neurono svorius atitinkantys vektoriai. Žali taškai – pirmos klasės (0), violetiniai taškai – antros klasės (1). Raudona – pirma tiesė (1), mėlyna – antra tiesė (2), geltona – trečioji tiesė (3). Taip pat vektorių spalvos atitinka tas pačias tieses.

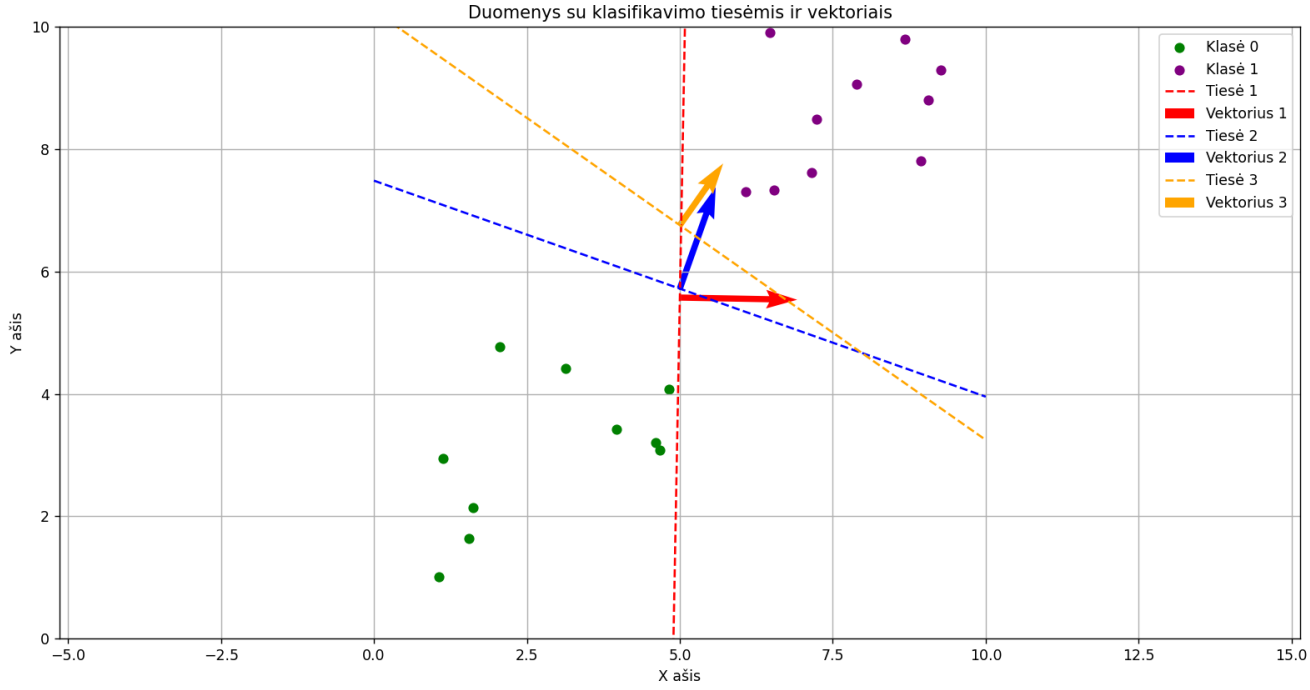

1.2 pav. Duomenų taškų ir klases skiriancių tiesių ir ju svorių vektorių grafikas

2. IŠVADOS

- Naudojant slenkstinę ar sigmoidinę funkcija rezultatai gaunasi tokie patys, nes sigmoidinė funkcija apvalinama iki 0 ar 1.
- Gautos tieses ir vektoriai vizualiai parodo kaip atskiriamos klases pagal dirbtinį neoroną, tai leidžia matyti kaip modelis priima sprendimus ir kokia įtaką turi skirtingi svoriai ir poslinkiai.
- Nors modelis veikia šiuo atveju, jis neveiktų jeigu duomenys persidengtų.

3. PAPILDOMA

Generuota:

- Vektorių vaizdavimo kodas
- Gramatinėm klaidom taisyti ataskaitoje